

ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
«САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
ПЕТРА ВЕЛИКОГО»

Физико-механический институт

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №1

«Гистограммы и плотности распределений»

Выполнил студент:

Мальшев Дмитрий Викторович
группа: 5030102/30201

Преподаватель:

Баженов Александр Николаевич

Санки-Петербург 2026

1 Постановка задачи

1.1 Цель работы

Целью данной лабораторной работы является изучение принципов группировки данных и построения гистограмм, а также исследование влияния объёма выборки на качество аппроксимации теоретического распределения.

1.2 Задачи работы

В ходе выполнения лабораторной работы необходимо решить следующие задачи:

1. Сгенерировать выборки объёмом $n = 10, 100, 1000$ для пяти различных распределений:
 - Нормальное распределение $N(x; 0, 1)$;
 - Распределение Коши $C(x; 0, 1)$;
 - Распределение Лапласа $L(x; 0, \frac{1}{\sqrt{2}})$;
 - Распределение Пуассона $P(k; 5)$;
 - Равномерное распределение $U(x; -\sqrt{3}, \sqrt{3})$.
2. Построить для каждой выборки гистограмму и наложить на неё теоретическую кривую плотности распределения (для дискретного распределения Пуассона — функцию вероятности).
3. Обеспечить оптимальное количество интервалов (бинов) гистограммы с использованием формулы Фридмана–Диакониса.
4. Провести анализ влияния размера выборки на определение характера распределения с помощью гистограммы.
5. Сформулировать выводы о качестве аппроксимации при различных объёмах выборок.

2 Теоретическая часть

2.1 Основные понятия

Гистограмма — это способ графического представления распределения числовых данных. Она строится путём разбиения диапазона значений на интервалы (бины) и подсчёта количества наблюдений, попавших в каждый интервал. Для сравнения с теоретической плотностью распределения используется нормированная гистограмма, где высота столбцов соответствует оценке плотности вероятности:

$$\hat{f}(x) = \frac{n_k}{n \cdot h}, \quad x \in \Delta_k, \quad (1)$$

где n_k — количество наблюдений в k -м интервале, h — ширина интервала, n — общий объём выборки.

2.2 Исследуемые распределения

В работе рассматриваются следующие распределения:

2.2.1 Нормальное распределение $N(x; 0, 1)$

Плотность вероятности:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad x \in \mathbb{R}. \quad (2)$$

Характеристики: математическое ожидание $\mu = 0$, дисперсия $\sigma^2 = 1$.

2.2.2 Распределение Коши $C(x; 0, 1)$

Плотность вероятности:

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad x \in \mathbb{R}. \quad (3)$$

2.2.3 Распределение Лапласа $L(x; 0, \frac{1}{\sqrt{2}})$

Плотность вероятности:

$$f(x) = \frac{1}{\sqrt{2}} e^{-\sqrt{2}|x|}, \quad x \in \mathbb{R}. \quad (4)$$

Характеристики: математическое ожидание $\mu = 0$, дисперсия $\sigma^2 = \frac{1}{2}$.

2.2.4 Распределение Пуассона $P(k; 5)$

Функция вероятности (для дискретной случайной величины):

$$P(X = k) = \frac{5^k e^{-5}}{k!}, \quad k = 0, 1, 2, \dots \quad (5)$$

Характеристики: математическое ожидание $\lambda = 5$, дисперсия $\lambda = 5$.

2.2.5 Равномерное распределение $U(x; -\sqrt{3}, \sqrt{3})$

Плотность вероятности:

$$f(x) = \frac{1}{2\sqrt{3}}, \quad x \in [-\sqrt{3}, \sqrt{3}]. \quad (6)$$

Характеристики: математическое ожидание $\mu = 0$, дисперсия $\sigma^2 = 1$.

2.3 Выбор количества интервалов

Для оптимального выбора количества интервалов гистограммы используется **формула Фридмана–Диакониса**:

$$h = 2 \cdot IQR \cdot n^{-1/3}, \quad (7)$$

где IQR — межквартильный размах (разность между 75-м и 25-м перцентилями), n — объём выборки. Количество интервалов определяется как:

$$k = \left\lceil \frac{\max(x) - \min(x)}{h} \right\rceil$$

Данный метод обеспечивает компромисс между излишней детализацией (шум) и потерей информации (сглаживание).

3 Реализация

3.1 Инструментарий

Работа выполнена на языке программирования Python 3.10 в среде разработки PyCharm. Используются следующие библиотеки:

- `numpy` — для генерации случайных чисел и численных расчётов;
- `matplotlib` — для визуализации данных;
- `scipy.stats` — для работы с теоретическими распределениями;
- `math` — для математических операций.

3.2 Методика реализации

Программа реализует следующий алгоритм:

1. Задание параметров пяти распределений (функции генерации выборок и теоретические плотности).
2. Для каждого объёма выборки $n \in \{10, 100, 1000\}$:
 - (a) Генерация выборки заданного объёма;
 - (b) Расчёт оптимального количества интервалов по формуле Фридмана–Диакониса (7);
 - (c) Построение нормированной гистограммы (1);
 - (d) Наложение теоретической кривой плотности (2)–(6) (для Пуассона — функции вероятности (5));
3. Формирование матрицы графиков размером 5×3 .
4. Вывод результатов.

4 Результаты

В результате выполнения работы были получены гистограммы для пяти распределений при трёх различных объёмах выборок. На рисунке 1 представлены все 15 графиков.




Рис. 1: Гистограммы выборок и теоретические плотности распределений для различных объёмов выборок

5 Обсуждение

5.1 Анализ влияния объёма выборки

По результатам, представленным на рисунке 1, можно сделать следующие наблюдения:

- **При $n = 10$:** гистограммы имеют ярко выраженный случайный характер и плохо отражают форму теоретического распределения. Например, для нормального распределения гистограмма может быть асимметричной или многовершинной из-за малого количества данных.
- **При $n = 100$:** форма распределения начинает прослеживаться, но всё ещё заметны статистические флуктуации. Количество интервалов, рассчитанное по формуле (7), обеспечивает хороший компромисс между сглаживанием и детализацией.
- **При $n = 1000$:** гистограмма практически совпадает с теоретической кривой плотности для всех непрерывных распределений. Для дискретного распределения Пуассона столбчатая диаграмма точно соответствует теоретической функции вероятности.

5.2 Особенности отдельных распределений

- **Распределение Коши:** даже при $n = 1000$ наблюдаются выбросы, что связано с тяжёлыми хвостами распределения. Это приводит к необходимости обрезания данных для визуализации.
- **Распределение Пуассона с $\lambda = 5$:** при таком параметре распределение становится достаточно симметричным, что хорошо видно на гистограммах.
- **Равномерное распределение:** наиболее быстро сходится к теоретической форме благодаря отсутствию «хвостов».

5.3 Связь с теорией

Полученные результаты подтверждают теоретические положения о состоятельности гистограмм как оценок плотности распределения. С увеличением объёма выборки гистограмма с оптимальным количеством интервалов сходится к истинной плотности вероятности.

6 Выводы

В ходе выполнения лабораторной работы были сделаны следующие выводы:

1. При малом объёме выборки ($n = 10$) гистограмма неинформативна и сильно зависит от случайности.
2. При среднем объёме ($n = 100$) гистограмма даёт приблизительное представление о форме распределения.
3. При большом объёме ($n = 1000$) гистограмма с оптимальным количеством интервалов практически точно воспроизводит теоретическую плотность.
4. Формула Фридмана–Диакониса (7) обеспечивает автоматический подбор оптимального количества интервалов в зависимости от объёма выборки и разброса данных.

Список литературы

- [1] Вентцель Е.С. Теория вероятностей: Учебник для вузов, 2005.
- [2] Документация библиотеки NumPy: <https://numpy.org/doc/stable/>
- [3] Документация библиотеки SciPy: <https://docs.scipy.org/doc/scipy/>

7 Приложение

Исходный код лабораторной работы доступен в репозитории GitHub по адресу:
<https://github.com/lostakey/MatStat/tree/lab1>