

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
**«САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
ПЕТРА ВЕЛИКОГО»**

Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №3

«Боксплот Тьюки и анализ выбросов»

Выполнил студент:

Мальшев Дмитрий Викторович
группа: 5030102/30201

Преподаватель:

Баженов Александр Николаевич

Санкт-Петербург 2026

1 Постановка задачи

1.1 Цель работы

Целью данной лабораторной работы является изучение метода визуализации одномерных распределений с помощью боксплота Тьюки, а также анализ доли выбросов в выборках из различных распределений в зависимости от объёма выборки.

1.2 Задачи работы

В ходе выполнения лабораторной работы необходимо решить следующие задачи:

1. Сгенерировать выборки объёмом $n = 20$ и $n = 100$ для пяти различных распределений:
 - Нормальное распределение $N(0, 1)$;
 - Распределение Коши $C(0, 1)$;
 - Распределение Лапласа $L(0, \frac{1}{2})$;
 - Распределение Пуассона $P(5)$;
 - Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$.
2. Построить боксплоты Тьюки для каждого распределения при каждом объёме выборки.
3. Определить долю выбросов экспериментально: для каждого распределения сгенерировать 1000 выборок заданного объёма и вычислить среднюю долю выбросов.
4. Проанализировать, как размер выборки влияет на долю отсеиваемых аномальных значений.
5. Сравнить полученные доли выбросов с теоретическими ожиданиями для различных распределений.

2 Теоретическая часть

2.1 Исследуемые распределения

В работе рассматриваются следующие распределения:

2.1.1 Нормальное распределение $N(0, 1)$

Плотность вероятности:

$$f(x) = \frac{1}{\sqrt{2\pi}} e^{-\frac{x^2}{2}}, \quad x \in \mathbb{R}. \quad (1)$$

Симметричное распределение с лёгкими хвостами.

2.1.2 Распределение Коши $C(0, 1)$

Плотность вероятности:

$$f(x) = \frac{1}{\pi(1+x^2)}, \quad x \in \mathbb{R}. \quad (2)$$

Имеет тяжёлые хвосты, что приводит к частым выбросам. Математическое ожидание не существует.

2.1.3 Распределение Лапласа $L(0, \frac{1}{2})$

Плотность вероятности:

$$f(x) = \frac{1}{2} e^{-|x|}, \quad x \in \mathbb{R}. \quad (3)$$

Имеет более тяжёлые хвосты, чем нормальное, но легче, чем Коши.

2.1.4 Распределение Пуассона $P(5)$

Функция вероятности:

$$P(X = k) = \frac{5^k e^{-5}}{k!}, \quad k = 0, 1, 2, \dots \quad (4)$$

Дискретное распределение с асимметрией.

2.1.5 Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$

Плотность вероятности:

$$f(x) = \frac{1}{2\sqrt{3}}, \quad x \in [-\sqrt{3}, \sqrt{3}]. \quad (5)$$

Распределение с ограниченным носителем, дисперсия равна 1.

2.2 Боксплот Тьюки (ящик с усами)

Боксплот Тьюки — графический метод представления одномерных распределений, основанный на квартилях. Основные элементы боксплота:

- **Нижняя граница ящика:** первый квартиль Q_1 (25-й процентиль)
- **Линия внутри ящика:** медиана Q_2 (50-й процентиль)

- **Верхняя граница ящика:** третий квартиль Q_3 (75-й процентиль)
- **Длина ящика:** межквартильный размах $IQR = Q_3 - Q_1$
- **Нижний ус:** $\max(\min(x), Q_1 - 1.5 \cdot IQR)$
- **Верхний ус:** $\min(\max(x), Q_3 + 1.5 \cdot IQR)$
- **Выбросы:** точки за пределами усов




Рис. 1: Схема боксплота Тьюки

2.3 Доля выбросов

Доля выбросов в выборке определяется как:

$$\text{Доля выбросов} = \frac{\text{Количество элементов за пределами усов}}{n} \quad (6)$$

Для нормального распределения теоретическая доля выбросов составляет примерно 0.7% с каждой стороны, т.е. около 1.4% суммарно.

3 Реализация

3.1 Инструментарий

Работа выполнена на языке программирования Python 3.10. Использованы следующие библиотеки:

- `numpy` — для генерации случайных чисел и численных расчётов;
- `scipy.stats` — для работы с теоретическими распределениями;
- `matplotlib` — для построения боксплотов.

4 Результаты

4.1 Боксплоты Тьюки

На рисунке 2 представлены боксплоты для всех распределений при объёмах выборок $n = 20$ и $n = 100$.




Рис. 2: Боксплоты Тьюки для исследуемых распределений

4.2 Средняя доля выбросов

В таблице 1 представлены средние доли выбросов, полученные по 1000 выборкам для каждого распределения и объёма выборки.

Таблица 1: Средняя доля выбросов (по 1000 выборок)

Распределение	$n = 20$	$n = 100$
Нормальное	0.0217	0.0095
Коши	0.1532	0.1560
Лапласа	0.0739	0.0646
Пуассона	0.0243	0.0149
Равномерное	0.0025	0.0000

5 Обсуждение

5.1 Анализ полученных результатов

- **Нормальное распределение:** Доля выбросов составляет около 2.17% при $n=20$ и снижается до 0.95% при $n=100$. Теоретическое значение для нормального распределения составляет примерно 1.4%. При увеличении объёма выборки наблюдается сходимость к теоретическому значению.
- **Распределение Коши:** Наблюдается самая высокая доля выбросов — около 15.3–15.6%, что примерно в 7 раз больше, чем для нормального распределения при $n=100$. Это объясняется тяжёлыми хвостами распределения Коши, которые генерируют экстремальные значения значительно чаще. При увеличении объёма выборки доля выбросов практически не меняется.
- **Распределение Лапласа:** Доля выбросов составляет около 7.4% при $n=20$ и 6.5% при $n=100$, что занимает промежуточное положение между нормальным распределением и распределением Коши. Это соответствует теории: хвосты распределения Лапласа тяжелее нормальных, но легче, чем у Коши.
- **Распределение Пуассона:** Доля выбросов около 2.4% при $n=20$ и 1.5% при $n=100$. При увеличении объёма выборки доля выбросов уменьшается и приближается к значениям нормального распределения, что связано с асимптотической нормальностью пуассоновских сумм.
- **Равномерное распределение:** Доля выбросов близка к нулю (0.25% при $n=20$ и 0% при $n=100$), что соответствует теории — равномерное распределение на отрезке $[-\sqrt{3}, \sqrt{3}]$ практически не имеет выбросов, так как все значения лежат в строго ограниченном интервале. Ненулевое значение при $n=20$ связано с дискретностью выборки и особенностями оценки квартилей при малых объёмах.

5.2 Влияние объёма выборки

При увеличении объёма выборки с 20 до 100 наблюдается:

- Для нормального распределения: уменьшение доли выбросов с 2.17% до 0.95% (приближение к теоретическому значению 1.4%);
- Для распределения Коши: стабилизация доли выбросов около 15.5%;
- Для распределения Лапласа: уменьшение с 7.4% до 6.5%;
- Для распределения Пуассона: уменьшение с 2.4% до 1.5%;
- Для равномерного распределения: стремление к нулю.

Это объясняется тем, что при больших выборках квартили и межквартильный размах лучше оценивают истинные параметры распределения, что приводит к более точному определению границ усов и, соответственно, к стабилизации доли выбросов около теоретических значений.

6 Выводы

В ходе выполнения лабораторной работы были сделаны следующие выводы:

1. **О боксплоте Тьюки:** Боксплот является эффективным инструментом визуализации одномерных распределений, позволяющим наглядно оценить:
 - центральную тенденцию (положение медианы);
 - разброс данных (длина ящика и усов);
 - симметричность распределения (положение медианы относительно квартилей);
 - наличие и количество выбросов.
2. **О доле выбросов в различных распределениях:**
 - Распределения с лёгкими хвостами (нормальное, равномерное) дают малую долю выбросов (0–2%);
 - Распределения с тяжёлыми хвостами (Коши) дают значительную долю выбросов (до 15.6%);
 - Распределение Лапласа занимает промежуточное положение (6.5–7.4%);
 - Дискретное распределение Пуассона при параметре $\lambda = 5$ при увеличении объёма выборки ведёт себя аналогично нормальному (сходимость доли выбросов к 1.5%).
3. **О влиянии объёма выборки:** При увеличении объёма выборки с 20 до 100 доля выбросов стабилизируется около теоретических значений. Для распределений с тяжёлыми хвостами (Коши) стабилизация происходит быстрее, для распределений с лёгкими хвостами требуется больший объём выборки для точной оценки.
4. **О практическом применении:** Боксплот Тьюки может служить первичным инструментом диагностики типа распределения. Например, большое количество выбросов (более 10%) может указывать на распределение с тяжёлыми хвостами (Коши, Лапласа), а их отсутствие — на распределение с ограниченным носителем (равномерное). Доля выбросов около 1-2% характерна для нормального распределения и распределений, сходящихся к нормальному при увеличении объёма выборки.

Список литературы

- [1] Вентцель Е.С. Теория вероятностей: Учебник для вузов. — М.: Высшая школа, 2005. — 576 с.
- [2] Тьюки Дж. Анализ результатов наблюдений. Разведочный анализ. — М.: Мир, 1981. — 693 с.
- [3] Орлов А.И. Прикладная статистика. — М.: Экзамен, 2004. — 656 с.
- [4] Документация библиотеки NumPy [Электронный ресурс]. — Режим доступа: <https://numpy.org/doc/stable/>
- [5] Документация библиотеки SciPy [Электронный ресурс]. — Режим доступа: <https://docs.scipy.org/doc/scipy/>

7 Приложение

7.1 Ссылка на репозиторий

Исходный код лабораторной работы доступен в репозитории GitHub по адресу:
<https://github.com/lostakey/MatStat/tree/lab3>