

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
**«САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
ПЕТРА ВЕЛИКОГО»**

Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №4

«Эмпирическая функция распределения и ядерные оценки плотности»

Выполнил студент:

Мальшев Дмитрий Викторович
группа: 5030102/30201

Преподаватель:

Баженов Александр Николаевич

Санкт-Петербург 2026

1 Постановка задачи

1.1 Цель работы

Целью данной лабораторной работы является изучение эмпирической функции распределения и ядерных оценок плотности, а также исследование их сходимости к теоретическим функциям при увеличении объёма выборки.

1.2 Задачи работы

В ходе выполнения лабораторной работы необходимо решить следующие задачи:

1. Сгенерировать выборки объёмом $n = 20, 60, 100$ для пяти различных распределений:
 - Нормальное распределение $N(0, 1)$;
 - Распределение Коши $C(0, 1)$;
 - Распределение Лапласа $L(0, \frac{1}{2})$;
 - Распределение Пуассона $P(5)$;
 - Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$.
2. Для каждой выборки построить:
 - Эмпирическую функцию распределения (э.ф.р.) совместно с теоретической функцией распределения;
 - Ядерную оценку плотности (с гауссовым ядром) совместно с теоретической плотностью распределения.
3. Построения выполнить на отрезке $[-4, 4]$ для непрерывных распределений и на отрезке $[6, 14]$ для распределения Пуассона.
4. Исследовать, как объём выборки влияет на приближение эмпирической функции к истинной функции распределения.
5. Сравнить два способа оценки плотности распределения: ядерные оценки и гистограммы.
6. Проанализировать скорость сходимости эмпирической функции распределения в соответствии с теоремой Гливенко–Кантелли.

2 Теоретическая часть

2.1 Исследуемые распределения

В работе рассматриваются следующие распределения (подробно описанные в лабораторной работе №2):

- Нормальное распределение $N(0, 1)$;
- Распределение Коши $C(0, 1)$;
- Распределение Лапласа $L(0, \frac{1}{2})$;
- Распределение Пуассона $P(5)$;
- Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$.

2.2 Эмпирическая функция распределения

Эмпирическая функция распределения (э.ф.р.) для выборки $X_1, X_2, \dots, X_n$ определяется как:

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I(X_i \leq x) \quad (1)$$

где $I(\cdot)$ — индикаторная функция.

Свойства эмпирической функции распределения:

- $F_n(x)$ — ступенчатая функция, возрастающая скачками величиной $1/n$ в точках выборки;
- Для любого фиксированного x величина $F_n(x)$ является несмещённой и состоятельной оценкой теоретической функции распределения $F(x)$;
- **Теорема Гливенко–Кантелли:** эмпирическая функция распределения сходится по вероятности к теоретической функции распределения равномерно по x :

$$\sup_{x \in \mathbb{R}} |F_n(x) - F(x)| \xrightarrow[n \rightarrow \infty]{\text{п.н.}} 0 \quad (2)$$

Скорость сходимости имеет порядок $O(1/\sqrt{n})$.

2.3 Ядерные оценки плотности

Ядерная оценка плотности (Kernel Density Estimation, KDE) — непараметрический способ оценки плотности вероятности. Для выборки $X_1, X_2, \dots, X_n$ оценка имеет вид:

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^n K\left(\frac{x - X_i}{h}\right) \quad (3)$$

где $K(\cdot)$ — ядро (неотрицательная функция, интегрируемая с единицей), h — параметр сглаживания (ширина окна).

В работе используется **гауссово ядро**:

$$K(u) = \frac{1}{\sqrt{2\pi}} e^{-\frac{u^2}{2}} \quad (4)$$

Свойства ядерных оценок:

- В отличие от гистограммы, ядерная оценка является непрерывной функцией (при использовании непрерывного ядра);
- Качество оценки сильно зависит от выбора ширины окна h : слишком малое h приводит к зашумлённой оценке, слишком большое — к излишнему сглаживанию;
- Ядерные оценки сходятся к истинной плотности при $n \rightarrow \infty$ и $h \rightarrow 0$ с определённой скоростью.

2.4 Сравнение гистограмм и ядерных оценок

Таблица 1: Сравнение гистограмм и ядерных оценок плотности

Гистограмма	Ядерная оценка
Ступенчатая функция Зависит от выбора числа бинов Не сглаживает данные Проста в вычислении	Непрерывная функция Зависит от выбора ширины окна Сглаживает данные Требуется больше вычислений

3 Реализация

3.1 Инструментарий

Работа выполнена на языке программирования Python 3.10. Использованы следующие библиотеки:

- `numpy` — для генерации случайных чисел и численных расчётов;
- `scipy.stats` — для работы с теоретическими распределениями и ядерными оценками;
- `matplotlib` — для визуализации результатов.

4 Результаты

4.1 Нормальное распределение $N(0, 1)$

На рисунке 1 представлены результаты для нормального распределения.




Рис. 1: Эмпирическая функция распределения и ядерные оценки плотности для нормального распределения

4.2 Распределение Коши $C(0, 1)$

На рисунке 2 представлены результаты для распределения Коши.




Рис. 2: Эмпирическая функция распределения и ядерные оценки плотности для распределения Коши

4.3 Распределение Лапласа $L(0, \frac{1}{2})$

На рисунке 3 представлены результаты для распределения Лапласа.




Рис. 3: Эмпирическая функция распределения и ядерные оценки плотности для распределения Лапласа

4.4 Распределение Пуассона $P(5)$

На рисунке 4 представлены результаты для распределения Пуассона.




Рис. 4: Эмпирическая функция распределения и ядерные оценки плотности для распределения Пуассона

4.5 Равномерное распределение $U(-\sqrt{3}, \sqrt{3})$

На рисунке 5 представлены результаты для равномерного распределения.




Рис. 5: Эмпирическая функция распределения и ядерные оценки плотности для равномерного распределения

5 Обсуждение

5.1 Анализ эмпирической функции распределения

Из полученных графиков и таблицы ?? можно сделать следующие наблюдения:

- При малом объёме выборки ($n = 20$) эмпирическая функция распределения имеет ступенчатый характер и заметно отличается от теоретической. Ступени имеют высоту $1/20 = 0.05$, что делает функцию грубой аппроксимацией.
- При увеличении объёма выборки до $n = 60$ эмпирическая функция становится более гладкой (высота ступеней $1/60 \approx 0.0167$) и лучше приближает теоретическую функцию.
- При $n = 100$ эмпирическая и теоретическая функции практически совпадают визуально, особенно для распределений с лёгкими хвостами (нормальное, равномерное).
- Для распределения Коши даже при $n = 100$ наблюдаются небольшие отклонения в хвостах, что связано с тяжёлыми хвостами этого распределения.
- Для дискретного распределения Пуассона эмпирическая функция также хорошо сходится к теоретической, но сохраняет ступенчатый характер, соответствующий дискретности распределения.

5.2 Сравнение ядерных оценок и гистограмм

- **Гистограммы:**

- При малых выборках ($n = 20$) гистограммы имеют малую информативность: либо слишком грубые (мало бинов), либо с большими флуктуациями (много бинов).
- При увеличении объёма выборки гистограммы лучше отражают форму распределения, но остаются ступенчатыми.

- **Ядерные оценки:**

- При $n = 20$ ядерные оценки дают сглаженную кривую, которая может как недооценивать пики, так и создавать ложные структуры из-за малого количества точек.
- При $n = 60$ и $n = 100$ ядерные оценки хорошо приближают теоретическую плотность, особенно для гладких распределений (нормальное, Лапласа).
- Для распределения Коши ядерные оценки могут иметь проблемы в хвостах из-за редких экстремальных значений.
- Для равномерного распределения ядерная оценка даёт сглаженные края вместо резких границ, что является особенностью метода.
- Для дискретного распределения Пуассона ядерная оценка даёт непрерывную аппроксимацию, что не совсем корректно с теоретической точки зрения, но может быть полезно для визуализации.

5.3 Преимущества и недостатки методов

- **Эмпирическая функция распределения:**

- + Простота вычисления и интерпретации;
- + Не требует выбора параметров;
- + Сходится к истинной функции распределения;
- Ступенчатый характер (не подходит для оценки плотности).

- **Гистограмма:**

- + Простота построения;
- Зависимость от выбора числа бинов;
- Ступенчатый характер;
- Чувствительность к границам бинов.

- **Ядерная оценка плотности:**

- + Непрерывность и гладкость;
- + Хорошая сходимость при оптимальном выборе ширины окна;
- Зависимость от выбора ширины окна;
- Большие вычислительные затраты.

6 Выводы

В ходе выполнения лабораторной работы были сделаны следующие выводы:

1. О сходимости эмпирической функции распределения:

- Экспериментально подтверждена теорема Гливенко–Кантелли: при увеличении объёма выборки эмпирическая функция распределения сходится к теоретической равномерно по x .
- Уже при $n = 100$ эмпирическая функция распределения визуально неотличима от теоретической для большинства распределений.

2. О ядерных оценках плотности:

- Ядерные оценки являются эффективным инструментом непараметрического оценивания плотности, особенно при наличии достаточного объёма выборки ($n \geq 60$).
- В отличие от гистограмм, ядерные оценки дают гладкую аппроксимацию плотности, что лучше соответствует реальным непрерывным распределениям.
- Для распределений с ограниченным носителем (равномерное) наблюдаются краевые эффекты — ядерная оценка "сглаживает" резкие границы.
- Для дискретных распределений (Пуассона) применение ядерных оценок требует осторожности, так как они дают непрерывную аппроксимацию вместо дискретных вероятностей.

3. Сравнение методов оценки плотности:

- Гистограммы проще в построении и интерпретации, но их ступенчатый характер является существенным недостатком при аппроксимации непрерывных распределений.
- Ядерные оценки требуют выбора параметра сглаживания (ширины окна), но при оптимальном выборе дают более точную и гладкую оценку плотности.
- Оба метода сходятся к истинной плотности при увеличении объёма выборки, но ядерные оценки обычно обеспечивают лучшую скорость сходимости для гладких распределений.

4. Практические рекомендации:

- Для визуализации распределения при малых выборках ($n < 30$) лучше использовать эмпирическую функцию распределения или гистограмму с небольшим числом бинов.
- При средних объёмах выборки ($30 \leq n \leq 100$) ядерные оценки дают хорошее представление о форме распределения.
- При больших выборках ($n > 100$) все методы дают схожие результаты, и выбор может определяться конкретной задачей.
- Для дискретных распределений предпочтительнее использовать гистограммы или эмпирическую функцию распределения, а не ядерные оценки.

Список литературы

- [1] Вентцель Е.С. Теория вероятностей: Учебник для вузов. — М.: Высшая школа, 2005. — 576 с.
- [2] Орлов А.И. Прикладная статистика. — М.: Экзамен, 2004. — 656 с.
- [3] Скотт Д.В. Многомерная статистическая оценка плотности. — М.: Мир, 1988. — 256 с.
- [4] Епанечников В.А. Непараметрическая оценка многомерной плотности вероятности // Теория вероятностей и её применения. — 1969. — Т. 14, № 1. — С. 156–161.
- [5] Документация библиотеки NumPy [Электронный ресурс]. — Режим доступа: <https://numpy.org/doc/stable/>
- [6] Документация библиотеки SciPy [Электронный ресурс]. — Режим доступа: <https://docs.scipy.org/doc/scipy/>
- [7] Документация библиотеки Matplotlib [Электронный ресурс]. — Режим доступа: <https://matplotlib.org/stable/contents.html>

7 Приложение

7.1 Ссылка на репозиторий

Исходный код лабораторной работы доступен в репозитории GitHub по адресу:
<https://github.com/lostakey/MatStat/tree/lab4>