

МИНИСТЕРСТВО НАУКИ И ВЫСШЕГО ОБРАЗОВАНИЯ РОССИЙСКОЙ ФЕДЕРАЦИИ
ФЕДЕРАЛЬНОЕ ГОСУДАРСТВЕННОЕ БЮДЖЕТНОЕ ОБРАЗОВАТЕЛЬНОЕ УЧРЕЖДЕНИЕ
ВЫСШЕГО ОБРАЗОВАНИЯ
**«САНКТ-ПЕТЕРБУРГСКИЙ ПОЛИТЕХНИЧЕСКИЙ УНИВЕРСИТЕТ
ПЕТРА ВЕЛИКОГО»**

Физико-механический институт
Высшая школа прикладной математики и вычислительной физики

ОТЧЁТ ПО ЛАБОРАТОРНОЙ РАБОТЕ №5

«Корреляционный анализ и эллипсы рассеивания»

Выполнил студент:

Мальшев Дмитрий Викторович
группа: 5030102/30201

Преподаватель:

Баженов Александр Николаевич

Санкт-Петербург 2026

1 Постановка задачи

1.1 Цель работы

Целью лабораторной работы является изучение методов корреляционного анализа, включая вычисление различных выборочных коэффициентов корреляции (Пирсона, Спирмена, квадрантного), а также визуализация структуры зависимости между случайными величинами с помощью диаграмм рассеяния и эллипсов рассеивания.

1.2 Задачи работы

В ходе выполнения работы необходимо решить следующие задачи:

1. Сгенерировать двумерные выборки объёмом $n = 20, 60, 100$ из:
 - Двумерного нормального распределения $N(0, 0, 1, 1, \rho)$ с коэффициентами корреляции $\rho = 0; 0.5; 0.9$;
 - Смеси распределений: $0.9 \cdot N(0, 0, 1, 1, 0.9) + 0.1 \cdot N(0, 0, 10, 10, -0.9)$.
2. Для каждой сгенерированной выборки вычислить:
 - коэффициент корреляции Пирсона r ;
 - коэффициент ранговой корреляции Спирмена r_s ;
 - квадрантный коэффициент корреляции r_Q .
3. Повторить генерацию и вычисления 1000 раз для каждого набора параметров, найти средние значения и дисперсии коэффициентов корреляции.
4. Построить диаграммы рассеяния с наложенными эллипсами рассеивания (на уровне двух стандартных отклонений) для каждого рассматриваемого случая (по одному примеру выборки).
5. Сравнить полученные значения коэффициентов корреляции с теоретическими, проанализировать влияние объёма выборки и наличия выбросов (в смеси) на устойчивость оценок.

2 Теоретическая часть

2.1 Двумерное нормальное распределение

Двумерная случайная величина (X, Y) имеет нормальное распределение, если её плотность вероятности задаётся выражением:

$$f(x, y) = \frac{1}{2\pi\sigma_x\sigma_y\sqrt{1-\rho^2}} \exp \left\{ -\frac{1}{2(1-\rho^2)} \left[\frac{(x-\bar{x})^2}{\sigma_x^2} - 2\rho \frac{(x-\bar{x})(y-\bar{y})}{\sigma_x\sigma_y} + \frac{(y-\bar{y})^2}{\sigma_y^2} \right] \right\} \quad (1)$$

где $\bar{x}, \bar{y}$ — средние значения, σ_x, σ_y — стандартные отклонения, а $\rho \in [-1, 1]$ — коэффициент корреляции, характеризующий степень линейной зависимости между X и Y .

2.2 Коэффициенты корреляции

Коэффициент корреляции Пирсона является мерой линейной зависимости и вычисляется по формуле:

$$r = \frac{\sum_{i=1}^n (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_{i=1}^n (x_i - \bar{x})^2 \sum_{i=1}^n (y_i - \bar{y})^2}} = \frac{\widehat{\text{cov}}(X, Y)}{s_X s_Y} \quad (2)$$

Он принимает значения от -1 до 1 , где ± 1 соответствует строгой линейной зависимости, а 0 — её отсутствию. Пирсоновский коэффициент чувствителен к выбросам и предполагает нормальность данных.

Коэффициент ранговой корреляции Спирмена основан на рангах наблюдений и менее чувствителен к выбросам. Пусть u_i и v_i — ранги x_i и y_i соответственно. Тогда:

$$r_s = \frac{\sum_{i=1}^n (u_i - \bar{u})(v_i - \bar{v})}{\sqrt{\sum_{i=1}^n (u_i - \bar{u})^2 \sum_{i=1}^n (v_i - \bar{v})^2}}, \quad \bar{u} = \bar{v} = \frac{n+1}{2} \quad (3)$$

Квадрантный коэффициент корреляции определяется через количество точек в квадрантах относительно медиан:

$$r_Q = \frac{(n_1 + n_3) - (n_2 + n_4)}{n} \quad (4)$$

где n_1, n_2, n_3, n_4 — число точек в соответствующих квадрантах декартовой системы с осями $x' = x - \text{med}(x)$, $y' = y - \text{med}(y)$. Этот коэффициент робастен к выбросам, так как опирается только на знаки отклонений от медиан.

2.3 Эллипсы рассеивания

Эллипсом рассеивания (равной плотности) для двумерного нормального распределения называется геометрическое место точек, в которых плотность вероятности постоянна. Уравнение эллипса:

$$\frac{(x-\bar{x})^2}{\sigma_x^2} - 2\rho \frac{(x-\bar{x})(y-\bar{y})}{\sigma_x\sigma_y} + \frac{(y-\bar{y})^2}{\sigma_y^2} = \text{const} \quad (5)$$

Ориентация и вытянутость эллипса определяются коэффициентом корреляции ρ : при $\rho = 0$ оси эллипса параллельны координатным осям; при $|\rho| \rightarrow 1$ эллипс вырождается в прямую. Эллипс, построенный по выборочным данным на уровне k стандартных отклонений, визуализирует ковариационную структуру выборки.

3 Результаты

3.1 Чистое нормальное распределение

На рисунке 1 представлены диаграммы рассеяния с эллипсами для нормальных выборок при различных значениях ρ и объёмах n . В таблице 1 приведены средние и дисперсии коэффициентов корреляции по 1000 повторениям.




Рис. 1: Диаграммы рассеяния и эллипсы для чистого нормального распределения при $n = 20, 60, 100$ и $\rho = 0; 0.5; 0.9$

Таблица 1: Средние и дисперсии коэффициентов корреляции (нормальное распределение, 1000 повторений)

n	ρ	Пирсон		Спирмен		Квадрантный	
		Среднее	Дисперсия	Среднее	Дисперсия	Среднее	Дисперсия
20	0	0.0060	0.053131	0.0049	0.051970	0.0004	0.051520
20	0.5	0.4911	0.030937	0.4621	0.034805	0.3216	0.048413
20	0.9	0.8972	0.002412	0.8692	0.004740	0.7092	0.028795
60	0	0.0007	0.016972	0.0005	0.017259	0.0027	0.017206
60	0.5	0.4988	0.010231	0.4794	0.011126	0.3333	0.015622
60	0.9	0.8972	0.000627	0.8813	0.001067	0.7043	0.008320
100	0	-0.0005	0.010020	0.0008	0.010071	0.0013	0.010283
100	0.5	0.4987	0.005586	0.4805	0.006339	0.3368	0.008825
100	0.9	0.8995	0.000358	0.8868	0.000578	0.7116	0.005055

3.2 Смесь распределений

На рисунке 2 показаны диаграммы рассеяния для смеси распределений. В таблице 2 приведены статистики коэффициентов корреляции.



Рис. 2: Диаграммы рассеяния и эллипсы для смеси распределений при $n = 20, 60, 100$

Таблица 2: Средние и дисперсии коэффициентов корреляции для смеси (1000 повторений)

n	Пирсон		Спирмен		Квадрантный	
	Среднее	Дисперсия	Среднее	Дисперсия	Среднее	Дисперсия
20	0.1562	0.274079	0.5158	0.060120	0.5230	0.038671
60	0.0671	0.120361	0.5374	0.022837	0.5535	0.012128
100	0.0204	0.074964	0.5388	0.014138	0.5644	0.006724

4 Обсуждение

4.1 Анализ чистого нормального распределения

- **Сходимость оценок.** С ростом объёма выборки все три коэффициента корреляции стремятся к истинному значению ρ .

- **Сравнение коэффициентов.** Для выборок без выбросов коэффициент Пирсона демонстрирует наименьшее смещение и дисперсию, что ожидаемо, так как он является оптимальной оценкой для нормальных данных. Коэффициент Спирмена немного уступает Пирсону в эффективности (дисперсия примерно на 5–10% выше), но сохраняет высокую точность. Квадрантный коэффициент имеет наибольшую дисперсию и смещение (особенно заметно при $\rho = 0.5$), что объясняется потерей информации при переходе к знаковым рангам.
- **Визуализация.** Эллипсы рассеивания наглядно отражают величину и знак корреляции. При $\rho = 0$ эллипс близок к окружности; при $\rho = 0.5$ заметна вытянутость; при $\rho = 0.9$ эллипс сильно сплюснут и ориентирован вдоль прямой $y = x$.

4.2 Влияние выбросов (смесь распределений)

Смесь содержит 10% наблюдений из распределения с высокой дисперсией и отрицательной корреляцией ($\rho = -0.9$), что имитирует грубые выбросы.

- **Пирсон.** Коэффициент Пирсона оказывается наиболее чувствительным. Выбросы сильно искажают ковариационную структуру, что видно и на эллипсах рассеивания — они заметно вытягиваются в направлении выбросов.
- **Спирмен.** Ранговая корреляция более устойчива. Это объясняется тем, что выбросы с большими значениями получают экстремальные ранги, но их влияние ограничено.
- **Квадрантный.** Квадрантный коэффициент робастен. Он практически игнорирует величину отклонений и учитывает только знаки, поэтому выбросы с большими значениями, но расположенные в «правильных» квадрантах, не искажают его. Однако потеря информации приводит к значительному смещению относительно истинного значения основной компоненты (0.9).

5 Выводы

В ходе выполнения лабораторной работы получены следующие результаты:

1. Экспериментально подтверждена состоятельность выборочных коэффициентов корреляции Пирсона, Спирмена и квадрантного для нормальных данных: с увеличением объёма выборки средние значения приближаются к истинному ρ , а дисперсии убывают.
2. Коэффициент Пирсона является наиболее эффективной оценкой при отсутствии выбросов, но крайне чувствителен к аномальным наблюдениям. В условиях зашумлённых данных (смесь) его значение может существенно отличаться от корреляции основной массы.
3. Коэффициент ранговой корреляции Спирмена демонстрирует компромисс между эффективностью и робастностью: он сохраняет приемлемую точность на чистых данных и заметно устойчивее Пирсона к выбросам.
4. Квадрантный коэффициент корреляции обладает наибольшей робастностью, однако его интерпретация затруднена из-за значительного смещения относительно истинного значения линейной корреляции. Его целесообразно применять для грубой оценки наличия монотонной зависимости.
5. Эллипсы рассеивания являются наглядным инструментом визуализации ковариационной структуры двумерных данных. Они позволяют быстро оценить степень и направление линейной связи, а также выявить наличие выбросов (по искажению формы эллипса).
6. При анализе реальных данных, особенно подверженных загрязнению, рекомендуется вычислять несколько коэффициентов корреляции и сравнивать их, а также дополнять численный анализ визуализацией с помощью эллипсов рассеивания.

Список литературы

- [1] Бабахина С.А., Баженов А.Н. Практикум по математической статистике: учебное пособие. — СПб.: СПбПУ, 2026.
- [2] Вентцель Е.С. Теория вероятностей: Учебник для вузов. — М.: Высшая школа, 2005.
- [3] Документация SciPy: Statistical functions (`scipy.stats`) [Электронный ресурс]. — URL: <https://docs.scipy.org/doc/scipy/reference/stats.html>
- [4] Документация Matplotlib: `matplotlib.patches.Ellipse` [Электронный ресурс]. — URL: https://matplotlib.org/stable/api/_as_gen/matplotlib.patches.Ellipse.html

6 Приложение

6.1 Ссылка на репозиторий

Исходный код лабораторной работы размещён в репозитории GitHub:
<https://github.com/lostonekey/MatStat/tree/lab5>